

Gaussian Mixture

2017 年 5 月 14 日

要約

ガウス混合分布を Gibbs Sampling と Collapsed Gibbs Sampling で考える。

1 Data Generating Process




図 1 Gaussian Mixture

$$\mu_k \sim \mathcal{N}(\mu_P, \sigma_P^2), \quad k = 1, \dots, K \quad (1)$$

$$\theta \sim \text{Dir}(\alpha), \quad \alpha = (\alpha_1, \dots, \alpha_K) \quad (2)$$

$$z_i \sim \text{Multi}(1|\theta), \quad i = 1, \dots, D \quad (3)$$

$$x_i \sim \mathcal{N}(u_{z_i=k}, \sigma^2), \quad i = 1, \dots, D \quad (4)$$

2 Gibbs Sampling

2.1 全確率変数の結合分布

$$p(\mathbf{x}, \theta, \mathbf{z}, \boldsymbol{\mu} | \alpha, \mu_P, \sigma_P^2, \sigma^2) \quad (5)$$

$$= p(\mathbf{x} | \mathbf{z}, \boldsymbol{\mu}, \sigma^2) p(\theta, \mathbf{z}, \boldsymbol{\mu} | \alpha, \mu_P, \sigma_P^2, \sigma^2) \quad (6)$$

$$= p(\mathbf{x} | \mathbf{z}, \boldsymbol{\mu}, \sigma^2) p(\mathbf{z} | \theta) p(\theta | \alpha) p(\boldsymbol{\mu} | \mu_P, \sigma_P^2) \quad (7)$$

$$= \prod_{i=1}^D \{p(x_i | \mu_{z_i}, \sigma^2) p(z_i | \theta)\} \cdot p(\theta | \alpha) \cdot \prod_{k=1}^K p(\mu_k | \mu_P, \sigma_P^2) \quad (8)$$

2.2 更新式

2.2.1 z_i のサンプリング

$$p(z_i = k | x_i, \mathbf{x}^{\setminus i}, \mathbf{z}^{\setminus i}, \boldsymbol{\theta}, \boldsymbol{\mu}, \boldsymbol{\alpha}, \mu_P, \sigma_P^2, \sigma^2) \quad (9)$$

$$\propto p(z_i = k, x_i, \mathbf{x}^{\setminus i}, \mathbf{z}^{\setminus i}, \boldsymbol{\theta}, \boldsymbol{\mu} | \boldsymbol{\alpha}, \mu_P, \sigma_P^2, \sigma^2) \quad (10)$$

$$= p(x_i | z_i = k, \mathbf{x}^{\setminus i}, \mathbf{z}^{\setminus i}, \boldsymbol{\theta}, \boldsymbol{\mu}, \boldsymbol{\alpha}, \mu_P, \sigma_P^2, \sigma^2) \cdot p(z_i = k | \mathbf{x}^{\setminus i}, \mathbf{z}^{\setminus i}, \boldsymbol{\theta}, \boldsymbol{\mu} | \boldsymbol{\alpha}, \mu_P, \sigma_P^2, \sigma^2) \quad (11)$$

$$= p(x_i | z_i = k, \mu_k, \sigma^2) \cdot p(z_i = k | \mathbf{x}^{\setminus i}, \mathbf{z}^{\setminus i}, \boldsymbol{\theta}, \boldsymbol{\mu}) \cdot p(\mathbf{x}^{\setminus i}, \mathbf{z}^{\setminus i}, \boldsymbol{\theta}, \boldsymbol{\mu} | \boldsymbol{\alpha}, \mu_P, \sigma_P^2, \sigma^2) \quad (12)$$

$$= p(x_i | \mu_{z_i=k}, \sigma^2) \cdot p(z_i = k | \boldsymbol{\theta}) \cdot p(\mathbf{x}^{\setminus i}, \mathbf{z}^{\setminus i}, \boldsymbol{\theta}, \boldsymbol{\mu} | \boldsymbol{\alpha}, \mu_P, \sigma_P^2, \sigma^2) \quad (13)$$

$$\propto \underbrace{p(x_i | \mu_{z_i=k}, \sigma^2)}_{\text{Normal Distribution}} \cdot \underbrace{p(z_i = k | \boldsymbol{\theta})}_{\theta_k} \quad (14)$$

2.2.2 $\boldsymbol{\theta}$ のサンプリング

$$p(\boldsymbol{\theta} | \mathbf{x}, \mathbf{z}, \boldsymbol{\mu}, \boldsymbol{\alpha}, \mu_P, \sigma_P^2, \sigma^2) \quad (15)$$

$$\propto p(\boldsymbol{\theta}, \mathbf{x}, \mathbf{z}, \boldsymbol{\mu} | \boldsymbol{\alpha}, \mu_P, \sigma_P^2, \sigma^2) \quad (16)$$

$$= p(\mathbf{x} | \boldsymbol{\theta}, \mathbf{z}, \boldsymbol{\mu}, \boldsymbol{\alpha}, \mu_P, \sigma_P^2, \sigma^2) p(\boldsymbol{\theta}, \mathbf{z}, \boldsymbol{\mu} | \boldsymbol{\alpha}, \mu_P, \sigma_P^2, \sigma^2) \quad (17)$$

$$= p(\mathbf{x} | \mathbf{z}, \boldsymbol{\mu}, \sigma^2) p(\mathbf{z} | \boldsymbol{\theta}) p(\boldsymbol{\theta} | \boldsymbol{\mu}, \boldsymbol{\alpha}, \mu_P, \sigma_P^2, \sigma^2) p(\boldsymbol{\mu} | \boldsymbol{\alpha}, \mu_P, \sigma_P^2, \sigma^2) \quad (18)$$

$$\propto \underbrace{p(\mathbf{z} | \boldsymbol{\theta})}_{\text{Multi}} \underbrace{p(\boldsymbol{\theta} | \boldsymbol{\alpha})}_{\text{Dir}} \quad (19)$$

$$\propto \prod_{k=1}^K \theta_k^{n_k + \alpha_k - 1}, \quad \text{where } n_k = \sum_{i=1}^D \delta(z_i = k) \quad (20)$$

$\boldsymbol{\theta}$ は Dirichlet 分布からなので正規化項も考えると、

$$\frac{\Gamma\left(\sum_{k=1}^K n_k + \alpha_k\right)}{\prod_{k=1}^K \Gamma(n_k + \alpha_k)} \prod_{k=1}^K \theta_k^{n_k + \alpha_k - 1} \quad (21)$$

2.2.3 μ_k のサンプリング

$$p(\mu_k | \boldsymbol{\mu}^{\setminus k}, \mathbf{x}, \mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\alpha}, \mu_P, \sigma_P^2, \sigma^2) \quad (22)$$

$$\propto p(\mu_k, \boldsymbol{\mu}^{\setminus k}, \mathbf{x}, \mathbf{z}, \boldsymbol{\theta} | \boldsymbol{\alpha}, \mu_P, \sigma_P^2, \sigma^2) \quad (23)$$

$$= p(\mathbf{x} | \boldsymbol{\mu}, \boldsymbol{\mu}^{\setminus k}, \mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\alpha}, \mu_P, \sigma_P^2, \sigma^2) p(\boldsymbol{\mu}, \boldsymbol{\mu}^{\setminus k}, \mathbf{z}, \boldsymbol{\theta} | \boldsymbol{\alpha}, \mu_P, \sigma_P^2, \sigma^2) \quad (24)$$

$$= p(\mathbf{x} | \boldsymbol{\mu}, \boldsymbol{\mu}^{\setminus k}, \mathbf{z}, \sigma^2) p(\mu_k | \mu_P, \sigma_P^2) p(\boldsymbol{\mu}^{\setminus k}, \mathbf{z}, \boldsymbol{\theta} | \boldsymbol{\alpha}, \mu_P, \sigma_P^2, \sigma^2) \quad (25)$$

$$\propto \underbrace{p(\mathbf{x} | \boldsymbol{\mu}, \mathbf{z}, \sigma^2)}_{\text{Normal}} \underbrace{p(\mu_k | \mu_P, \sigma_P^2)}_{\text{Normal}} \quad (26)$$

$$\propto \prod_{k=1}^K \left[\left\{ \prod_{i=1}^D \frac{1}{\sqrt{\sigma^2}} \exp\left(-\frac{(x_i - \mu_k)^2}{2\sigma^2}\right) \cdot \delta(z_i = k) \right\} \times \left\{ \frac{1}{\sqrt{\sigma_P^2}} \exp\left(-\frac{(\mu_k - \mu_P)^2}{2\sigma_P^2}\right) \right\} \right] \quad (27)$$

Wikipedia の Conjugate prior の記事を参考にすると、更新後の平均は、

$$\left(\frac{\mu_P}{\sigma_P^2} + \frac{\sum_{i=1}^D x_i \cdot \delta(z_i = k)}{\sigma^2} \right) / \left(\frac{1}{\sigma_P^2} + \frac{\sum_{i=1}^D \delta(z_i = k)}{\sigma^2} \right), \quad k = 1, \dots, K \quad (28)$$

分散は、

$$\left(\frac{1}{\sigma_P^2} + \frac{\sum_{i=1}^D \delta(z_i = k)}{\sigma^2} \right)^{-1}, \quad k = 1, \dots, K \quad (29)$$

となる。

3 Collapsed Gibbs Sampling

θ と μ を積分消去する。このときのグラフィカルモデルは以下ようになる。




図2 Collapsed Gibbs Sampling

周辺化されることで、隠れ変数やデータに依存関係が生まれていることに注意する必要がある。依存関係があるため、 z を全て同時にサンプリングすることはできないが、 z_1, \dots, z_D のように 1 つずつサンプリングすることは可能である。ある z_i は、それ以外のデータ $\mathbf{z}^{\setminus i}$ が与えられた状態でサンプリングする。

$$p(z_i = k | x_i, \mathbf{x}^{\setminus i}, \mathbf{z}^{\setminus i}, \alpha, \mu_P, \sigma_P^2, \sigma^2) \quad (30)$$

$$\propto p(z_i = k, x_i, \mathbf{x}^{\setminus i}, \mathbf{z}^{\setminus i} | \alpha, \mu_P, \sigma_P^2, \sigma^2) \quad (31)$$

$$= p(x_i | z_i = k, \mathbf{x}^{\setminus i}, \mathbf{z}^{\setminus i}, \alpha, \mu_P, \sigma_P^2, \sigma^2) p(z_i = k, \mathbf{x}^{\setminus i}, \mathbf{z}^{\setminus i} | \alpha, \mu_P, \sigma_P^2, \sigma^2) \quad (32)$$

$$= p(x_i | z_i = k, \mathbf{x}^{\setminus i}, \mathbf{z}^{\setminus i}, \alpha, \mu_P, \sigma_P^2, \sigma^2) p(z_i = k | \mathbf{x}^{\setminus i}, \mathbf{z}^{\setminus i}, \alpha, \mu_P, \sigma_P^2, \sigma^2) p(\mathbf{x}^{\setminus i}, \mathbf{z}^{\setminus i} | \alpha, \mu_P, \sigma_P^2, \sigma^2) \quad (33)$$

$$\propto p(x_i | z_i = k, \mathbf{x}^{\setminus i}, \mathbf{z}^{\setminus i}, \alpha, \mu_P, \sigma_P^2, \sigma^2) p(z_i = k | \mathbf{x}^{\setminus i}, \mathbf{z}^{\setminus i}, \alpha, \mu_P, \sigma_P^2, \sigma^2) \quad (34)$$

$$= p(x_i | z_i = k, \mathbf{x}^{\setminus i}, \mathbf{z}^{\setminus i}, \mu_P, \sigma_P^2, \sigma^2) p(z_i = k | \mathbf{x}^{\setminus i}, \mathbf{z}^{\setminus i}, \alpha) \quad (35)$$

$$= \int p(x_i | z_i = k, \mu, \mathbf{x}^{\setminus i}, \mathbf{z}^{\setminus i}, \mu_P, \sigma_P^2, \sigma^2) p(\mu | z_i = k, \mathbf{x}^{\setminus i}, \mathbf{z}^{\setminus i}, \mu_P, \sigma_P^2, \sigma^2) d\mu \quad (36)$$

$$\times \int p(z_i = k | \theta, \mathbf{x}^{\setminus i}, \mathbf{z}^{\setminus i}, \alpha) p(\theta | \mathbf{x}^{\setminus i}, \mathbf{z}^{\setminus i}, \alpha) d\theta \quad (37)$$

$$= \int p(x_i | z_i = k, \mu_k, \sigma^2) p(\mu_k | \mathbf{x}^{\setminus i}, \mathbf{z}^{\setminus i}, \mu_P, \sigma_P^2, \sigma^2) d\mu_k \int p(z_i = k | \theta) p(\theta | \mathbf{z}^{\setminus i}, \alpha) d\theta \quad (38)$$

$$= \mathcal{N}(x_i | \mu_{\text{New}}, \sigma^2) \cdot \frac{n_k^{\setminus i} + \alpha_k}{\sum_{k=1}^K n_k^{\setminus i} + \alpha_k} \quad (39)$$

式 (38) は、それぞれ x_i 、 z_i に関する予測分布 (posterior predictive distribution)^{*1}であると解釈することができる。第 1 項は Normal と Normal、第 2 項は Multinomial (Categorical) と Dirichlet である。

^{*1} Wikipedia, Conjugate Prior: https://en.wikipedia.org/wiki/Conjugate_prior#Table_of_conjugate_distributions

式 (39)*²については、今回 σ を明示的に与えているので σ^2 の更新はない。もし、 σ^2 もベイズにするのなら、

$$\int p(x_i|z_i = k, \mu_k, \sigma^2) p(\mu_k, \sigma_k^2 | \mathbf{x}^{\setminus i}, \mathbf{z}^{\setminus i}, \mu_P, \sigma_P^2) d\mu_k d\sigma_k^2 \quad (40)$$

のような形になるはず。

式 (38) の初項に関しては、 μ_k の期待値 ($\overline{\mu_k}$) を使う近似を考えてしまっても良い。

$$p(x_i|z_i = k, \mu_k, \sigma^2) \int p(\mu_k | \mathbf{x}^{\setminus i}, \mathbf{z}^{\setminus i}, \mu_P, \sigma_P^2, \sigma^2) d\mu_k \quad (41)$$

$$= p(x_i|z_i = k, \overline{\mu_k}, \sigma^2) \quad (42)$$

μ_k は色々な値を取りうるけれども、正規分布に従う。データが十分にあれば、 μ_k の事後分布は十分に尖った形になるので期待値で代表させたもので近似しても良い。

*² これが計算しているのは、「事後分布のヒストグラム」になるはず。事後分布のヒストグラムから z を選ぶ。